Emora 双课题调研 · 综合评审与统一建议

- 调研日期：2026-10-31
- 执行主体：OpenClaw 主会话（QClaw）
- 目标项目：`emora-mvp-standalone`
- 关联报告：`01-■■A-■■■■■■■■■■■■.md`、`02-■■B-■■■■■■■■■.md`、`■■■■■■.md`

1. 执行摘要

两份课题从两个正交维度审视同一个问题：如何让 Emora 更专业、更可靠地提供情感支持。

- 课题 A（专业知识） 问的是「知不知道怎么安慰」——答案是：把 Rogers 底座 + MI(OARS) 技法工程化进结构化 prompt，并用 MITI/MISC-2 派生的 rubric 量化。
- 课题 B（原生能力） 问的是「模型本身能出多少力」——答案是：别指望换更新模型（共情代际无差异），而要用本确定性接口（strict json_schema + reasoning_effort），并兜住「建议安全性下降 + 表演式共情」两个原生风险。

两份课题的结论高度收敛：真正的提升来自「确定性工程（prompt + schema + 评测）」，而非「更大的模型或更多外部组件」。

2. 双课题的关系与交叉点

交叉点	课题 A 视角	课题 B 视角	统一结论
共情无法靠换模型提升	需专业知识工程化	三代模型共情无差异（arXiv 2603.09997）	靠 prompt + 评测，不靠换代
建议安全性	MI 明确「不诊断、不强迫改变」	原生建议安全性代际下降	双门禁 + 方法边界共同兜底
冗长/表演式共情	反映性倾听要求简洁	推理模型「复杂度惩罚」（ICDH 2026）	评测加入「简洁性」维度
结构化输出	结果要能进 rubric	strict json_schema 提升通过率	原生 schema 是评测的「数据质量底座」

3. 统一技术建议（MVP 唯一组合）

方向	建议	变更类型
专业方法	Rogers 底座 + MI-OARS 分层 prompt；CBT 重框作核心新增（零依赖）	核心新增
评测	DeepEval（pytest 原生）+ MI 忠诚度 rubric + 简洁性 rubric + 安全路由回归	核心新增
结构化输出	补 `response_format=json_schema strict`	小改动
推理深度	深思考试点 `reasoning.effort=high`	小改动（试点）
安全护栏	维持 Qwen3Guard-Gen；以 AILuminate(Practice) 为外部对齐评测标准	维持 + 新对齐评测
Agent 框架	维持 LangGraph 1.2.18	不变
RAG / 工具 / 微调	不引入	非目标

4. 三项必须贯彻的「否决性事实」

- 不换模型提升共情：arXiv 2603.09997（共情 H=4.33 p=0.115）——任何「升级到 GPT-6 会更好」的假设都不成立。
- 原生能力的反噬必须兜底：建议安全性下降（H=16.63 p<0.001）+ 表演式共情（ICDH 2026）——评测与门禁不是可选项。

- 第三方中转不可作事实依据：`ruoli.dev`
  上游路由无公开资料，本调研不采信其行为结论；原生能力（reasoning/structured outputs）经第三方中转是否透传不可验证。

5. 实施路线（阶段化）

阶段 0（本周，零依赖）

- 分层 prompt：Rogers 底座 + MI-OARS（改 `backend/prompts/system.md` 文案，不动架构）。
- 建立 MI 忠诚度 rubric + 20 – 30 条中文金标集。

阶段 1（评测闭环）

- DeepEval 接入 `backend/tests/`（pytest 原生），落自定义 metric：MI 忠诚度、简洁性、安全路由。
- A/B：现状 prompt vs MI 增强 prompt。

阶段 2（原生能力）

- `backend/provider.py` 补 strict json_schema（核对 required 全覆盖）。
- 深思考试点 reasoning_effort=high + 冗长度回归。

阶段 3（仅在有数据后）

- 重新评估是否微调（LLaMA-Factory）——当前不启动。

6. 风险清单

风险	缓解
MI 反映性倾听被模型「表演式共情」污染	简洁性 rubric + 人工抽检
原生建议安全性下降	Qwen3Guard 输出门禁（现有）+ AILuminate 回归
strict json_schema 与现有 schema 不兼容	逐字段核对 required，保持 Pydantic 兜底
中文 MI 量表适配不足	用简化 rubric，先金标集后量表

7. 结论

Emora 的专业能力提升，不靠更大的模型、不靠新框架、不靠训练数据，而靠三条确定性工程：(1) 把 Rogers+MI 写进 prompt；(2) 补原生结构化输出与可调推理深度；(3) 用 DeepEval + 专属 rubric + 安全门禁建立可回归的评测闭环。 对此，两份课题的证据一致、可追溯、可复现。

（综合报告完）