课题 A：专业知识增强情感支持能力 —— 技术调研报告

- 调研日期：2026-10-31
- 执行主体：OpenClaw 主会话（QClaw）
- 目标项目：`emora-mvp-standalone`（情绪复盘助手 MVP）
- 报告性质：技术选型调研 + 证据交叉审查，不含任何生产代码修改

1. 执行摘要

本报告回答一个问题：能否、以及如何把可复现的「专业对话方法」工程化进 Emora，从而增强其情感支持能力。

核心结论：

- 在可用的专业方法中，只有 Motivational Interviewing（MI，动机式访谈）具备「可编码、可复现、可评分」的完整工程化证据链（MITI / MISC-2 忠诚度编码系统有公开学术实证），这是把「专业知识」变成「可回归测试的软件能力」的唯一可靠路径。
- Rogers 人本取向（共情、无条件积极关注、真诚一致）应作为 Emora 的「底座语气」，它天然契合 Emora 现有的「情绪反思、不诊断、区分事实与假设」设计，但本身缺乏强 AI 实证，只宜作底座、不作评分主线。
- CBT（认知行为疗法）只能作「认知重框」参考技能，不能作主导方法：多篇证据一致表明 LLM「可辅助识别/重框不合理想法，但不应被依赖主导 CBT 交付」，且 Emora 的 PRD 明确排除「医疗诊断、治疗替代」。
- 最硬的实证结论是：方法的选择胜于模型的换代。arXiv 2603.09997 的临床测量显示 GPT-4o→o4-mini→GPT-5-mini 三代模型「共情得分无统计学显著差异」，真正改变的是「安全姿态」而非共情能力——这意味着想提升情感支持，靠换新模型不可行，必须靠专业知识（prompt 工程 + 专用评估）。

2. 背景与目标

2.1 背景

Emora 是一款「情感复盘助手」，目标是帮成年用户整理和理解自己的情感困扰，给出有依据、可理解、可执行的下一步建议（`emora-mvp-standalone/doc/PRD.md`）。当前实现只有一套通用情绪复盘 system prompt（`backend/prompts/system.md`），没有任何显式的专业对话方法工程化。

2.2 目标

- 梳理可工程化的专业对话方法及其证据强度；
- 判断哪些方法能与 Emora 的 LangGraph 工作流、安全门禁、结构化输出契约融合；
- 给出「专业知识增强」的落地建议与可验证的评测 rubric。

2.3 范围与方法

- 只调研公开、可引用的学术/官方来源（JMIR、JAMA Network Open、ACL Anthology、arXiv、PubMed 等）；
- 对无公开证据的实践（如内部自研疗法框架）不纳入结论；

- 交叉审查：同一结论至少有一篇独立来源支撑或被显式标注为单一来源。

3. Emora 架构基线（只读检查，非历史描述）

- 编排：`langgraph==1.2.18` 单节点 StateGraph（START→agent→END），单次 Agent 调用（`backend/agent.py`）。
- 结果契约：`AnalysisResult` = summary / emotions / conflict / user_needs / suggestions / next_step / safety_note（`backend/contracts.py`）。
- 安全：Qwen3Guard-Gen 输入+输出双门禁；程序控制权与 Agent 决策权严格分离，Agent 不能自主调用工具、写库、改状态（`doc/TECHNICAL_DESIGN.md` §2）。
- 澄清：单轮 `ask_clarification`，上限 1 轮。

对课题 A 的关键含义：Emora 的「结果 schema」本身已经是「结构化情感复盘」，天然适合把专业方法作为「节点内结构化 prompt + 输出校验 rubric」落地，而不需要引入任何「疗法框架 SDK」（这类 SDK 事实上不存在成熟开源的）。

4. 专业对话方法逐一分析

4.1 Rogers 人本取向（Person-Centered）

核心技法：共情理解、无条件积极关注、真诚一致。

证据：作为心理治疗通用态度，Rogers 取向广泛被用作聊天机器人「底座语气」，但针对「LLM 工程化 Rogers 取向」的强实证稀缺。它是「无争议但测不细」的方法。

对 Emora 的适用性：高，且已部分实现。Emora 现有 system prompt 的「不诊断、区分事实与假设、不用绝对化断言、不操纵他人」正是人本取向的工程化雏形。建议显式命名并固化为底座语气，但不作为度量主线。

4.2 Motivational Interviewing（MI，动机式访谈）

核心技法：OARS —— 开放式提问（Open questions）、肯定（Affirmations）、反映性倾听（Reflections）、总结（Summarization）；促进「change talk」（改变性语言）。

证据（本方向最强）：

- 可编码评估系统成熟：MITI（Motivational Interviewing Treatment Integrity）与 MISC-2（Manual for the MI Skill Code 2.0）能逐轮编码对话的 MI 忠实度——这为把 MI 变成「可回归测试的软件 rubric」提供了现成的、有学术背书的评分框架。
- ACL 2025（Findings）「A Fully Generative MI Counsellor Chatbot」：用 GPT-4o + MI 构建戒烟咨询聊天机器人（MIBot），与临床科学家协作迭代，106 名参与者实测，并用自动化 + 人工评估验证「机器人 MI 忠实度」与「来访者回应」。结论：LLM 能稳定承载 MI 结构化对话。
- JAMA Network Open（2026-03）MI 对齐研究：154 个高保真 MI 会话、3706 个治疗师回合，发现 LLM 与治疗师「语义相似度低、但情境适当性更高」，并强调「prompt engineering 对 MI 对齐至关重要」。这条直接印证：MI 的落地在「prompt + 评估」，不在「换更大的模型」。
- JMIR Formative（2026）「Aimi」：把 MI 策略操作化为「LLM 结构化工作流」，专家 MI 教练用 MISC-2 评分验证会话忠实度；证明「MI 策略 + 工作流节点」是与 LangGraph 形态天然契合的路径。

对 Emora 的适用性：最高。Emora 的目标（帮用户梳理矛盾与诉求、给可执行下一步）与 MI「协作式探索改变动机」高度吻合；MI 明确「不诊断、不强迫改变」，不会让系统滑向医疗诊断。

4.3 CBT（认知行为疗法）

核心技法：Catch It（捕捉不合理自动化想法）→ Check It（检验其真实性）→ Change It（重框为更现实的认知）。

证据（结论审慎）：

- JMIR AI（2024）「Can LLMs Replace Therapists?」：系统评估 LLM 完成 CBT 三阶段任务，明确结论「LLM 可提供识别/重框不合理想法的合理建议，但不应被依赖来主导 CBT 交付」。
- CBT-Bench（arXiv 2410.13218）：把 CBT 能力拆成「知识获取→认知模型理解→治疗性回应生成」三级，为「LLM 辅助 CBT」提供了可复现的评测阶梯。

对 Emora 的适用性：中。Emora 可把「识别不合理的自动化想法 → 温和检验 → 重框」作为可选认知技能融入 suggestions/next_step，但明确不主导、不诊断（与 PRD 一致）。

4.4 Hill Helping Skills（三阶段模型）

核心：Exploration（探索）→ Insight（洞察）→ Action（行动）。

证据：主要用于咨询师训练，AI 工程化实证弱。

对 Emora 的适用性：概念层面可吸收（探索≈现状澄清、洞察≈核心矛盾/需求识别、行动≈下一步），但不作为独立工程方法。Emora 现有 schema 已隐含此三阶段结构。

5. 技术方案对比（如何把「方法」变成「代码」）

方案	描述	证据强度	对 Emora 契合度
单一大 prompt 注入原则	在 system prompt 写 MI 原则	中（JAMA 提示「prompt 关键」）	高，零架构变动
结构化工作流（LangGraph 节点）	每个 MI 技法是节点/子步骤	高（Aimi JMIR 2026）	**最高**，与现有 StateGraph 融合
微调/RLHF 对齐疗法	训练模型说 MI 话术	中（EVA、Empathy-R1 已有；但 Emora 无数据）	低（MVP 无标注数据，见课题 B）
检索增强（RAG 注入疗法手册）	检索 MI/CBT 手册片段作上下文	低（无强公开实证；且 PRD 排除检索）	低

结论：MVP 采用「结构化工作流 + 节点内显式 MI 原则 prompt」，零新框架、零新依赖。

6. 学术证据汇总（关键文献）

文献	方法	核心发现	来源
MIBot（ACL 2025 Findings）	MI	LLM 稳定承载 MI 结构化戒烟对话，106 人实测	aclanthology.org/2025.findings-acl.1283
MI 对齐研究	MI	LLM 语义相似度低、情境适当性高；prompt 工程关键	jamanetwork.com/.../2846839
Aimi	MI	MI 策略→结构化工作流，MISC-2 评分验证	formative.jmir.org/2026/1/e94036
MIBot 反射生成	MI	GPT-4 生成 backward-looking complex reflection，需治疗师验证	mental.jmir.org/2024/1/e53778
LLM 替代治疗师？	CBT	LLM 可辅助识别/重框，不可主导 CBT	ai.jmir.org/2024/1/e52500
CBT-Bench	CBT	CBT 三级能力评测基准	arxiv.org/abs/2410.13218
共情未变，安全姿态变了	跨代测量	GPT 三代共情无显著差异（H=4.33, p=0.115）	arxiv.org/abs/2603.09997
EEE 框架	通用共情	GPT-4 经定向 prompt 后情感支持接近人类咨询师	pubmed/40706502

7. 优缺点分析

7.1 MI 作为主方法的优点

- 有可复现的评分系统（MITI/MISC-2），可工程化为评测 rubric；
- 与 Emora 目标、PRD 边界、LangGraph 结构三方契合；
- 明确「不诊断」，合规风险低。

7.2 MI 的缺点 / 风险

- OARS 的「反映性倾听」对模型细腻度要求高，需要 pipeline 校验（模型可能「表演式共情」，见课题 B 的 ICDH 2026 证据）；
- MITI/MISC-2 原始量表是临床编码工具，直接搬用需简化、需中文适配（原始以英文会话为主）；
- 只有 prompt+评估路线，短期无法用「更多数据训练」提升（MVP 无数据）。

7.3 CBT 的适用条件

- 仅当用户明确表达「想法卡住了/反复担心某事」等认知困扰时，提供「Catch-Check-Change」式轻量重框；
- 必须保留「这是想法的一种可能，不是诊断」的口径。

8. 对 Emora 的适用性结论

- 底座：Rogers 人本取向（显式化现有 design）。
- 主线：MI 的 OARS，作为结构化 prompt 写入 LangGraph 的 agent 节点。
- 可选技能：CBT 认知重框（Catch-Check-Change），仅在认知困扰场景触发。
- 不采用：Hill 三阶段作为独立方法（概念吸收即可）、任何疗法 SDK/检索注入。

9. 架构设计建议（最小侵入）

```
Emora ■■■agent ■■■■■■■
  ■■ system prompt: ■■■■■■■■
        ↓ ■■■
  system prompt (■■):
    1) ■■: Rogers ■■■■■■■■■■
    2) ■■: MI-OARS ■■■■■■■■ + ■■■
    3) ■■■: ■■■/■■■■■■/■■■■■■■■■
    4) ■■: ■■■■■■■Catch-Check-Change■■■■■■■■
```

关键点：不引入新的 LangGraph 节点（保持单节点 + 单轮澄清），全部落在 prompt 与 `AnalysisResult` 契约的字段语义内。这是「专业知识增强」与「MVP 规模」的最优平衡。

10. 实验验证方案

- 构建 MI 忠诚度 rubric（从 MITI/MISC-2 简化的中文版）：维度 = 开放式提问比例、反映性倾听（简单/复杂反映）、肯定、避免「直接给建议/过早诊断」。
- 金标集：20 – 30 条中文情感困扰输入 + 专家（或资深咨询师）标注的「理想回应要点」。
- 基线 vs 增强 A/B：同一模型、同一输入，对比「现状 prompt」与「MI 增强 prompt」的 rubric 得分。
- LLM-as-judge + 人工抽检：用 DeepEval 自定义 metric（见综合报告 § 评测）跑 LLM 裁判，再抽 10% 人工复核，避免自评分偏差。
- 安全回归：确认 MI 增强不改变安全路由（Unsafe 仍阻断、Controversial 仍放行、Suicide/Violent 仍引导现实求助）。

验收标准：增强版在「开放式提问 + 反映性倾听」两维显著优于基线，且安全路由回归零退化。

11. 结论

课题A的答案是确定的：Emora应把Rogers人本取向固化为底座、把MI的OARS作为显式技法工程化进现有的结构化prompt，并配套一个从MITI/MISC-2简化来的MI忠诚度评测rubric。专业知识增强不依赖换模型、不依赖新框架、不依赖训练数据，是当前性价比最高、证据最硬、合规最稳的路线。

12. 建议优先级

优先级	动作	依据
P0	分层prompt：Rogers底座 + MI-OARS技法	零新依赖、证据硬
P0	建立MI忠诚度rubric + 金标集（20 – 30条）	让「增强」可量化
P1	CBT认知重框作为可选技能（Catch-Check-Change）	有条件触发，审慎
P2	中文MI编码量表的系统性适配与校验	原始量表为英文
不启动	疗法微调、疗法RAG、Hill独立方法	无数据 / PRD排除 / 证据弱

（本期报告完）